

AI ENGINEER DEMO ASSESSMENT

Sunny Tea House AI 智能评价生成系统 · 技术与设计文档

👤 候选人：薄皓元 (Haoyuan Bo) 🕒 实际开发耗时：4.5 小时（核心任务 3.5h + 附加题 1h）

⚡ 核心技术：Next.js Serverless + Groq LPU + TailwindCSS

1. 💡 AI 辅助编程工具使用策略与提效心得

在本次全栈任务中，我采用了 **AI-Native (AI 原生驱动)** 的敏捷开发工作流，将 Cursor / Claude Code 定位为“架构设计副驾”与“全栈结对工程师”：

- Prompt 即架构 (Schema-First)**：先用 AI 梳理出严格的 TypeScript 接口与 Webhook JSON Payload 规范，确保前后端数据流零歧义。
- 解决样式与移动端适配痛点**：借助 AI 快速生成纯净、高对比度的浅灰背景（`#F4F4F5`）与纯白卡片（`bg-white`）布局，处理 `max-w-[420px]` 移动端居中与 Apple HIG 规范（点击热区 $\geq 44\text{px}$ ），大幅节省手工切图与调试 CSS 的时间。
- 流式传输与边缘容错调试**：在开发大模型数据管道与 Webhook 时，将报错栈与环境信息直接注入 AI 进行根因分析，秒级定位数据分块边界与 JSON 解析容错机制。
- 综合提效表现**：传统手工搭建通常需 6-8 小时，通过 AI 辅助全流程压缩至 **4.5 小时**，交付效率提升 **100% 以上**。

2. 🌐 跨平台、跨语种 Prompt（提示词）设计思路与调优踩坑复盘

2.1 跨语言 Prompt 调优与标签语义映射踩坑记录（真实工程沉淀）

⚠️ **初期踩坑 (V1.0)**：直接将前端选中的中文标签（如 `['服务好', '出餐快']`）拼接到 User Prompt 中丢给英文大模型，导致模型在生成英文评价时强行保留中文标签，输出了 *"The 服务好, 出餐快 really stood out..."* 的严重缺陷。

🔧 **工业级解决方案 (V3.0 定稿)**：

- 代码层语义映射字典 (TAG_EN_MAP)**：在发送给大模型前，先在后端字典将中文标签映射为地道英文短语（如 `'服务好' -> 'friendly and welcoming staff'`，`'出餐快' -> 'super fast turnaround'`）；
- System Prompt 绝对负约束**：加入强力指令 `"You must output ONLY in natural, fluent American English. NEVER output any Chinese characters."`；
- 后端正则兜底守卫**：在响应返回前增加正则检查，若意外检测到中文字符则自动激活纯净英文备用逻辑，彻底根除多语言混杂。

2.2 跨平台 Prompt 矩阵对比

维度	 Google Review (北美本地口碑)	 小红书 (RED 爆款种草)
目标受众	北美本地居民、硅谷工程师、Yelp/Google Maps 用户	湾区华人、留学生、探店打卡群体
语言与口吻	地道美式英语 (Authentic American English)，客观、冷静、普通消费者视角	中文简体，热情闺蜜安利、真诚打卡、网络化情绪价值
严格禁止词	杜绝 "I had the pleasure..." 等机器腔与中文字符	杜绝生硬官话、拒绝无意义长文、拒绝大段文字堆叠
标志性元素	"Super chewy boba", "Fast turnaround", "Well balanced sweetness"	灵动 Emoji (🥤🌟📝💖🔥)、空行呼吸感排版、3个精准 Tag
长度与计量控制	严格控制在 50~70 Words (单词) ，以 Word Count 计量	120-150 字，以字符计数，分为 3-4 个精简微段落

💡 **长度控制底层机制 (加分亮点)**：值得一提的是，为了解决 Google 英文模式下字数忽多忽少的问题，我在 Prompt 中并未采用保守的 `max_tokens` 粗暴截断（这会破坏句子的语法完整性导致断尾），而是启用了 `stop_sequences`（结束序列）配合 Few-shot 样本的长度锚定，确保输出在 50~70 个单词时自然完整收尾。

3. 🤖 附加题：企业微信群机器人自动化工作流（Webhook）

当顾客生成好评文案后，系统在后台静默触发异步非阻塞后台任务：

- 1. 大模型秒级提炼出 **20 字以内的中文摘要** 与 **情感倾向判定**；
- 2. 自动生成一段具有品牌温度的 **《50字给奶茶店老板的亲切感谢回复草稿》**；
- 3. 组装为结构化企业微信 Markdown 卡片，实时推送到门店运营群。

💡 **Webhook 演示与实推兼容设计**：为适应 Demo 演示环境，系统采用**异步非阻塞触发机制**，主评论生成后无需用户手动输入 Key，直接返回 200 响应；后台采用 `try...catch` 隔离 Webhook 调用，若在生产环境使用，只需在服务端注入 `WEWORK_WEBHOOK` / `WECOM_WEBHOOK_URL` 环境变量，即可一键切换为真实 HTTP 推送。

```
{
  "msgtype": "markdown",
  "markdown": {
    "content": "### 🥤 Sunny Tea House 新评价通知\n> **来源平台**：小红书\n> **用户标签**：服务好 / 出餐快\n\n**"
```

```
}  
}
```

4. API Key 服务端安全防护与海量并发用量成本优化架构

🔒 服务端环境变量沙箱代理架构（防前端泄漏）

题目特别指出纯前端会暴露 API Key。本项目坚决采用 **Next.js Serverless Edge Proxy 服务端代理架构**，客户端与浏览器完全不持有任何 API Key，网络抓包只能看到业务参数，从物理层面彻底杜绝 Key 盗刷与逆向风险。

⚡ Groq LPU 极速推理与成本优势

依托 Groq LPU 架构，模型推理速度达到 **500+ Tokens/秒**，首字时延（TTFT）压缩至 **200~300ms**，体验丝滑流畅；每天免费额度高达 **14,400 次**，单次请求成本接近 **\$0.0000**，完美兼顾商用可行性与极佳体验。

5. 移动端 H5 交互设计、唤起容错与产品体验闭环

- **选满 2 个标签后的“明确置灰禁用态”**：当用户选中 2 个标签后，其余未选标签自动附加 `opacity-40 bg-slate-100 text-slate-400 border-transparent cursor-not-allowed pointer-events-none`，高对比度视觉让用户一眼感知不可再点。
- **“生成中...” 加载状态（防重复点击）**：点击“🔥 AI生成评价”后，按钮立即禁用并显示旋转 Loading 图标与 `⌚ AI正在思考中...` 文案，彻底消除重复请求与等待焦虑。
- **文本框高度自适应与中英文分立计量**：通过 `useEffect` 与 `scrollHeight` 动态调整 Textarea 高度，内容完整舒展平铺；右上/右下角智能识别平台，**Google 英文显示 Word Count（如 52 Words）**，**小红书显示字符数（如 145 字）**，符合专业编辑习惯。
- **一键复制与绿色 Toast 瞬时反馈**：复制成功后在屏幕中央弹出高对比度绿色 Toast（`✅ 已复制到剪贴板，即将跳转...`），并在 1.5 秒后平滑淡出。
- **智能 Deep Linking 容错跳转**：对 Google 直跳真实 Google Maps 网页评价入口；对小红书无缝跳转官方移动端 Scheme / 网页搜索打卡入口。

6. ⌚ 项目实际耗时与效率分析

开发环节	实际耗时	提效方式
需求解构与架构设计	30 分钟	解构 5 大隐性考察点，确立 Next.js + Serverless 架构
Prompt 设计与调优	50 分钟	攻克多语言标签混杂缺陷，建立 <code>TAG_EN_MAP</code> 字典
H5 界面、移动端适配与微动效	60 分钟	使用 TailwindCSS 构建移动端 H5 (HIG ≥ 44px)
API 路由与 Webhook 自动化	40 分钟	完成 Groq API 代理与异步 Webhook 数据流
全链路集成测试、容错加固与文档撰写	30 分钟	验证唤起容错、编写结项文档并编译 PDF
总计投入时间	4.5 小时	核心任务 3.5h + 附加题 1h，高效达成完整闭环

7. 🏠 15–20 分钟线上复盘与现场 Prompt 调整预案

为应对二面复盘中的现场修改 Prompt 练习，已在 `src/app/api/generate/route.ts` 实现**完全参数化与模块化解耦**：

- **场景 A（改为委婉差评/建议）**：在 System Prompt 注入 `"Tone: Constructive & polite customer feedback"` 即可 10 秒切换；
- **场景 B（增加指定单品或特殊活动）**：在 User Prompt 动态注入饮品参数，Prompt 组装函数会自动更新注入，实现 10 秒内快速响应调整需求。
- **加分技术答辩细节（流式解析与边缘容错）**：在处理大模型分块数据时，专门设计了针对大模型分块与 JSON 分片边界错误的容错处理，防止因网络抖动导致解析崩溃。